

LSTM-Based Multimodal Model for Self-Harm Prediction Combining Mental Health Case Reports and Biometric Signals

정신건강 증례지와 생체 신호를 결합한 LSTM 기반 멀티 모달 자타해 예측 모델

Ri-Ra Kang¹, Yongyom Kim², Minseok-Hong³, Jeung-hoon Yang⁴, Yong-Min An⁵, KangYoon Lee⁶

강리라¹, 김용겸², 홍민석³, 양정훈⁴, 안용민⁵, 이강윤⁶

¹ Master Course, Department of IT Convergence Engineering, Gachon University, Republic of Korea,
rirakang@gachon.ac.kr

² Master Course, Department of IT Convergence Engineering, Gachon University, Republic of Korea,
gyom1204@gachon.ac.kr

³ Clinical Research Fellow, Department of Neuropsychiatry, Seoul National University Hospital,
Republic of Korea, garam21th@gmail.com

⁴ Professor, Department of Psychiatry, Chungnam National University Sejong Hospital,
Republic of Korea, bakira2002@naver.com

⁵ Professor, Department of Neuropsychiatry, Seoul National University Hospital, Republic of Korea,
aym@snu.ac.kr

⁶ Professor, Department of Computer Engineering Gachon University, Republic of Korea,
keylee@gachon.ac.kr

Corresponding author: KangYoon Lee

Abstract: This study focuses on developing an Artificial Intelligence (AI) model for more accurately predicting and preventing impulsive suicidal behaviors in psychiatric wards by integrating Case Report Form (CRF) data with biosignal data. The data utilized in this research consists of CRF information collected from Seoul National University Hospital, Yongin Mental Hospital, and Dongguk University Hospital, along with biosignal data gathered using wearable devices provided by HealthConnect Inc. Considering the complexity of the data, missing and outlier detections were conducted, followed by dimension reduction through SHAP Value analysis to enhance the applicability of the model in actual clinical environments. The AI model developed in this paper is based on LSTM (Long Short-Term Memory) and features a multi-input structure that can simultaneously process CRF data and biosignal data. This approach not only accounts for the patterns of changing biosignals over time but also considers the comprehensive clinical characteristics of patients to assess the risk of suicide. Notably, this model proposes a new methodology by utilizing sensor data for the early detection of impulsive suicidal actions, distinguishing it from traditional methods reliant on mental scales or voice analysis. By exploring the potential application of AI in mental health care and suicide prevention, particularly in high-risk environments like psychiatric wards, this study offers a novel approach to detecting and preventing impulsive suicidal behaviors. It is anticipated that this research will improve the quality of mental health services and provide a foundation for more effective interventions for at-risk patients, thereby enhancing the overall management and prevention of suicide.

Received: April 03, 2024; 1st Review Result: May 06, 2024; 2nd Review Result: June 12, 2024
Accepted: July 25, 2024

Keywords: LSTM, Biosignal Data, Multi-input Model, SHAP Value, Wearable Device

요약: 본 연구는 정신병동에서 발생할 수 있는 충동적 자타해 행위를 더 정밀하게 예측하고 방지하기 위한 목적으로, 증례지 데이터와 생체 신호 데이터를 통합하여 분석하는 인공지능(AI)모델 개발에 중점을 둔다. 연구 대상 데이터는 서울대병원, 용인정신병원, 동국대병원에서 수집된 각 환자의 증례지 정보와 헬스케어(주)에서 제공하는 웨어러블 디바이스를 통해 수집된 생체 신호 데이터로 구성된다. 이러한 데이터의 복잡성을 고려하여 결측치 및 이상치 탐지 후, SHAP Value 분석을 통해 CRF에서 핵심변수를 선별하고 차원을 축소함으로써 실제 임상 환경에서의 응용 가능성을 높였다. 본 논문에서 개발된 AI 모델은 LSTM을 기반으로 하여, 증례지 데이터와 생체 신호 데이터를 동시에 처리할 수 있는 다중 입력 구조를 갖추고 있다. 이는 시간에 따라 변화하는 생체 신호의 패턴뿐만 아니라, 환자의 임상적 특성을 종합적으로 고려하여 자살 위험성을 평가한다. 특히, 이 모델은 충동적 자살 행위의 사전 감지에 있어 센서 데이터의 활용이라는 새로운 방법론을 제안함으로써, 기존의 정신 척도나 음성 분석 등에 의존한 방법들과 차별화된다. 정신 건강 관리와 자살 예방 분야에서 AI의 적용 가능성을 탐색하며, 특히 정신병동과 같은 높은 위험도를 가진 환경에서의 충동적 자살 행위 감지 및 예방에 기여할 수 있는 새로운 방법론을 제시한다. 이를 통해, 향후 정신 건강 서비스의 질을 향상시키고, 위험에 처한 환자들에게 보다 효과적인 개입을 제공할 수 있는 기반을 마련할 것으로 기대된다.

핵심어: LSTM, 생체신호데이터, 다중입력모델, SHAP Value, 웨어러블 디바이스

1. 서론


전 세계적으로 자살은 꾸준히 심각한 공중 보건 문제로 자리 잡고 있다. 세계보건기구(WHO)의 최근 보고에 따르면, 매년 70만명이 자살로 생을 마감하며, 이는 40초에 한 명꼴로 자살하는 것을 의미한다. 자살은 전 세계 사망 원인 중 4위를 차지하는 주된 요인 중 하나로 기록되어 있으며, 이러한 통계는 자살 예방과 정신 건강 증진이 긴급히 필요함을 시사한다[1]. 국내 상황도 예외는 아니다. 대한민국 보건복지부가 발표한 2021년 정신건강실태 조사 결과에 따르면, 성인 4명 중 1명이 정신 건강 문제를 겪고 있으나, 정신 장애로 진단받은 인구 중 단 12.1%만이 전문가의 치료를 받고 있는 것으로 나타났다[2]. 국내 관련법상 정신의료기관 전문의 1인당 환자를 60명까지 담당하기 때문에, 이는 OECD에서 가장 높은 수준이다. 제도적 차원에서도 이 문제가 방치되어 정신건강의학과 입원환경 개선은 현재 시급한 문제이다. 이는 정신건강에 대한 접근성과 이용률이 심각하게 제한적임을 드러내는 동시에, 정신 건강 서비스의 수요에 비해 공급이 현저히 부족하다는 점을 보여준다. 서울시를 예로 들면, 2022년 기준으로 인구 10만 명당 정신건강 전문 인력은 23명에 불과하며, 이는 증가하는 정신 장애 환자 수를 감당하기에는 역부족이며, 특히 폐쇄 병상에서의 자타해 관리가 어렵다는 문제를 지적한다[3]. 이러한 배경 속에서 인공지능(AI) 기술의 헬스케어 적용은 혁신적인 전환점을 제시한다. AI를 통한 정밀 의료는 환자별 맞춤 치료를 가능하게 하며, 의료 분야의 다양한 난제에 대한 해결책을 제공할 수 있다는 기대를 모으고 있다[4]. 멘탈 헬스케어 분야, 특히 자타해 연구는 이러한 기술 혁신의 최전선에 서 있다. 현재까지의 연구들은 우울증 척도 예측과 같은 정신병관련 예측을 진행해 오거나[5][6], 주로

정신척도와 각종 인구학적정보가 들어있는 증례지 데이터를 기반으로 진행되어왔다. [7-9] 정신병동과 같이 높은 충동성을 가진 환경에서는 이러한 접근법이 충분하지 않을 수 있다. 2017년 미국에서 진행된 파일럿 연구에서는 정신과 입원환자 28명에게 스마트폰을 제공하여 스스로 생각과 행동을 기록하게 하고, 블루투스 센서를 이용하여 환자의 행동과 위치를 추적하며 기록했다. 이 연구는 망상, 물질 금단, 신체활동의 변화량 감소, 병동의 소음이 폭력 행동과 연관이 있음을 발견했다[10]. 이러한 선행 연구와 같이 정신병동 내에서 센서를 이용한 모니터링 연구가 진행된 바 있다. 본 연구는 이러한 연구를 바탕으로 하여, 정신병동과 같은 높은 위험도를 가진 환경에서 충동적 자살 행위를 감지하고 예방하는 새로운 방법론을 제시한다. 이를 통해 향후 정신 건강 서비스의 질을 향상시키고, 위험에 처한 환자들에게 보다 효과적인 개입을 제공할 수 있는 기반을 마련할 것으로 기대된다. 특히, 본 논문은 센서를 이용하여 자타해 예측을 즉각적으로 수행하는 것을 목표로 하여 기존 연구와 차별화된 방향성을 가지고 있다.

2. 연구 과정

2.1 데이터 수집

각 데이터들은 서울대병원, 용인정신병원, 동국대병원 정신병동에서 수집하였다. 연구대상자들은 3개 기관의 네트워크에서 총 240명을 모집할 예정이며, 본 논문에서 사용된 환자들은 총 97명을 대상으로 진행하였다. 본 연구에서는 환자의 사생활 정보의 보호를 위해 연구에 참여하는 인원만 연구 자료를 열람할 수 있도록하며, 연구 자료에 비밀번호를 사용하여 보완 시책을 수립하여 IRB의 검증을 받았다. 또한 폐쇄병동의 입원중인 환자는 취약한 연구대상자에 해당할 가능성이 있으며, 그 가운데 다수는 의사결정능력이 없을 가능성이 높다. 이에 따라 연구자들이 서울대병원 IRB와 구두로 상의했을 때, 의사결정능력이 없는 입원 환자는 취약한 연구대상자에 해당하며, 이 경우 보호자 또는 대리인의 동의를 취득하도록하였다.



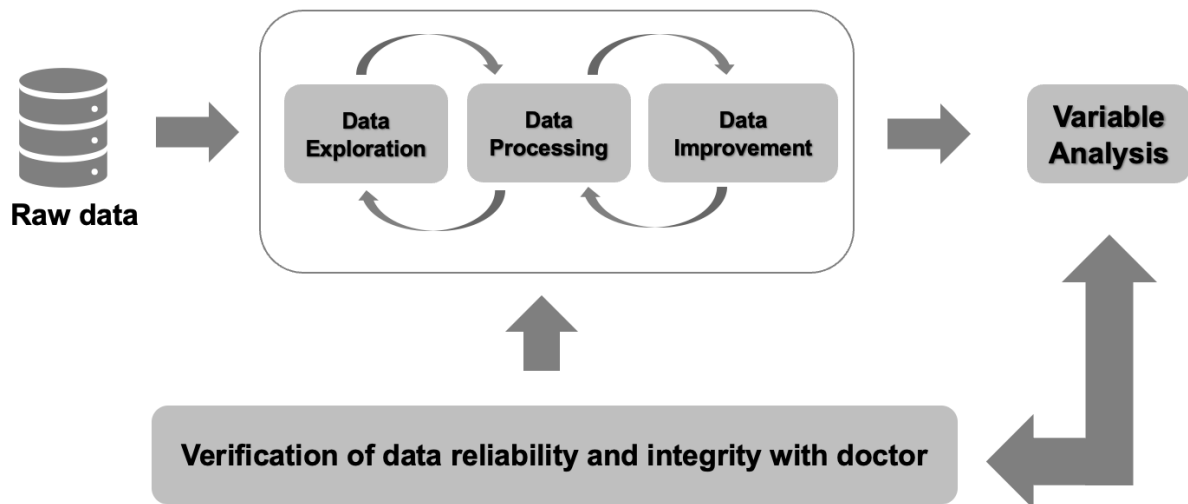
[그림 1] BLE 게이트웨이를 통해 수집한 생체 신호 데이터

[Fig. 1] Biosignal Data Collected through BLE Gateway

모집된 인원을 입원 기간 동안 추적 관찰하였다. 입원 7일 이내에 등록하였으며 환자는 wearable device를 착용한 상태로 병동 생활을 권고하였지만, 셔워나 병동 외부로

나가서 검사를 받아야 할 때, 외출할 때는 벗을 수 있도록 하였다. 대상자가 wearable device를 파괴하거나, 데이터 수집이 50% 이상의 시간동안 제대로 이뤄지지 않은 경우 연구를 종료하였다. 환자의 생체 신호 데이터를 획득하고 가공할 수 있는 시스템을 개발하여 환자의 활동 및 생체정보의 수집을 위한 웨어러블 기기의 도입을 진행하였다. 본 연구의 참여연구기관 중 하나인 헬스커넥트(주)가 참여하였으며, 생산된 의료용 스마트밴드의 제품 공급을 담당하여 생체 신호 데이터를 추출하였다. 환자에게 제공한 스마트밴드에서 획득한 실시간 생체정보와 수면, 활동이력등을 [그림 1]과 같이 BLE 게이트웨이를 통하여 수집하였고 저장할 수 있는 환경을 구축하였다.

증례지는 인구학적정보, 진단정보, 투약정보, 임상적 척도의 평가는 연구간호사에 의해 수행되었으며, 각 기관마다 1명 이상의 연구원을 배정시켰다. 양질의 증상 평가를 위해 모든 평가는 2년 이상의 임상 경력을 갖추고, 40시간 이상의 맞춤 훈련 코스를 이수한 국내면허 간호사들이 진행하였다. 평가자들은 초기 훈련 코스를 이수한 국내면허 간호사들이 진행하였다. 평가자들은 초기 훈련 이후에도 매2주 간격의 정신건강의학과 전문의가 주관하는 연구 컨퍼런스로 CRF 작성의 신뢰도를 확보하였다.



[그림 2] 데이터 수집 및 처리 단계 구성도

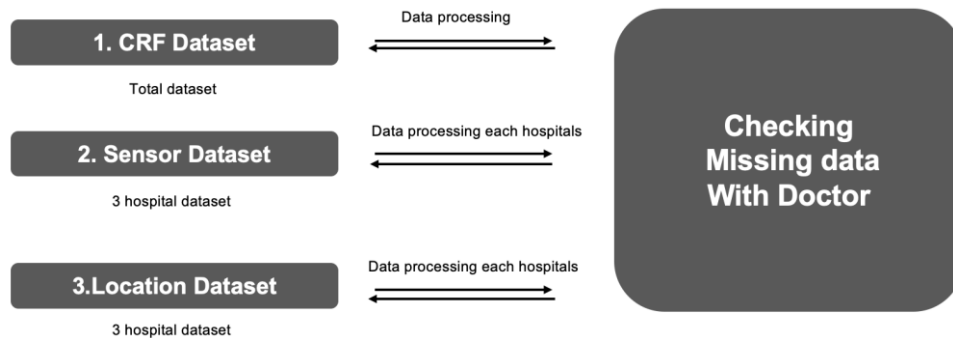
[Fig. 2] Data Collection and Processing Steps Diagram

3개의 병원에 대한 표준화된 CRF를 구축하고 이에 따른 환자의 다학제적 정보 수집도 표준화하여 진행하였다. 또한 딥러닝 모델의 훈련에서 불필요한 편향을 줄이기 위해 서울대병원 정신 병동의 전문의와 협력하여 [그림 2]와 같이 월 간격으로 추출된 데이터의 신뢰성 및 무결성을 확인하였다.

2.2 데이터 구성

본 데이터 구성은 CRF데이터와 wearable device를 통하여 수집한 생체 신호 데이터 그리고 위치 데이터로 이루어져있다. 게이트웨이로 수집된 생체 신호 데이터와 위치 데이터는 [그림 3]과 같이 서울대병원, 용인정신병원, 동국대병원별로 데이터 셋이 구성이 되어있으며 CRF 데이터는 통합된 데이터로 구성되어있다. 본 연구는 CRF 데이터, 생체

신호 데이터를 이용하여 모델을 구축한다. 추후 위치데이터를 추가 작업하여 예측모델을 고도화 할 예정이다.



[그림 3] 데이터 구성도

[Fig. 3] Data Diagram

2.3 CRF 데이터 구성


본 데이터 구성은 CRF_TRAIT 데이터와 CRF_STATE 두 종류의 데이터로 나누어져있다. 서울대병원, 용인정신병원, 동국대병원 3개의 병원 CRF_TRAIT 데이터는 시간에 따라 바뀌지 않은 환자의 정보이며 주로 초기 면담 때 얻은 데이터이다. CRF_STATE는 Timestamp가 중요한 정보이고 초기(initial), 주간(weekly), 응급(emergency) 평가로 구분 된다. TRAIT데이터는 주로 인구학적 평가와 의학적 병력 평가가 들어가있다. 인구학적 평가에는 생년월일, 학력, 직업, 성별, 월 가구 수입, 도시/농어촌, 사법처분의 기왕력의 데이터로 이루어져있다. 의학적 평가는 신체질환, 정신질환, 정신과 치료현황, 약물복용력이 존재한다. 약물 복용력은 평가 시점에 정신건강의학과에서 사용중인 약물을 기록하였다. STATE는 18개의 항목으로 이루어져있으며 넓은 범위의 정신병적 증상을 평가하는 BPRS, 조증 증상을 평가하는 YMRS, 불안 증상을 평가하는 HAM-A, 우울증상을 평가하는 MADRS, 자살생각과 자살행동의 평가를 하는 C-SSRS, 폭력위험성에 대한 평가인 HCR-20, AUDIT, CTQ, BIS, ASRS로 이루어져있는 자가보고 평가로 구성되어 있다. 인구학적정보와 의학적 병력평가, 각종 정신척도로 이루어진 두개의 데이터를 병합하여 CRF 데이터를 구성하였다. CRF의 outcome은 자타해 위험 행동은 다기관 측정의 정확도와 신뢰도를 위해 병동 내에서 위험행동으로 격리, 강박, 주사처치를 받은 경우로 해당 처치를 받은 시점을 기록하였다. CRF 데이터는 변수가 많아 임상적으로 쓰기위해 연구에서 SHAP VALUE 를 사용하여 변수 선택을 하였다.

2.4 생체 신호 데이터 구성

Hearbeat 변수는 심박수를 나타내며, step 변수는 걸음 수를 나타낸다. Calories, distance, sleep 변수는 각각 소비칼로리, 이동 거리, 수면 지수를 나타내며 battery 변수는 장치의 배터리 상태를 나타낸다. accelerationXais, accelerationYais, accelerationZais, angularXais, angularYais, angularZais는 환자의 각속도와 가속도를 나타낸다. 여기서 환자의 각속도는 측정이 모호하여 제외하였다.

2.5 데이터 분포

병동 내 환자의 인구학적 특성 분포를 상세히 조사하였다. 수집된 인구학적 변수에는 나이, 성별, 결혼 상태, 교육 수준, 직업, 종교, 한 달 수입, 신체 질환 여부, 정신 질환 유무, 등이 포함되었다. 연령 분포를 살펴본 결과, 20대와 30대의 청년층이 병동 내에서 두드러지게 많은 비율을 차지하는 것으로 나타났다. 이는 젊은 성인기에 발생할 수 있는 다양한 정신 건강 문제에 대한 관심을 촉구하는 동시에, 이 연령대를 대상으로 한 예방 및 개입 프로그램의 중요성을 강조한다. 한달 수입과 관련하여서는 [그림 4]와 같이 0에서 1000 사이의 수입을 보고한 환자의 비율이 상대적으로 높았다.



(a) 정신병동 내 환자의 나이
(a) Age of patients in psychiatric wards

(b) 정신병동 내 환자의 한달 수입
(b) monthly income of patients in psychiatric wards

[그림 4] 정신병동 내의 데이터분포(수치)

[Fig. 4] Data Suicide Rate

각 범주형 변수에 대한 상세한 탐색을 통해 환자 인구의 특성 분포에 관한 통찰을 제공한다. 특히, [표 1] 과 같이 인구통계학적 특성이 환자 데이터에서 두드러지게 나타났다. 성별로는 여성 환자가 남성 환자보다 많았으며, 결혼 여부에 있어서는 미혼인 환자의 비율이 높았다. 교육 수준은 고등학교 졸업이 가장 큰 비중을 차지하였으며, 종교가 없는 환자들의 비율도 주목할 만하게 나타났다. 직업과 관련해서는 무직인 환자들이 상당한 부분을 차지했으며, 이는 위와 월 수입과의 관계를 보았을때 경제적 요인이 정신건강에 미치는 영향을 데이터상 고려해볼 수 있다. 신체 질환의 유무는 데이터 세트에서 명확하게 구분되었으며, 특히 정신질환을 가진 환자들 중에서는 조현병을 진단받은 개인들의 비율이 상당히 높게 나타났다.

2.6 데이터 전처리

이상치는 센서 데이터에서 발견되었으며 이 데이터는 튀는값이므로 삭제를 진행하였으며, CRF에서의 이상치는 존재하지않았다. CRF 결측치는 0으로 대체하였다. 센서데이터의 가속도 x 가속도 y 가속도 z 값은 아래 수식과 같이 계산을하여 기존의 x,y,z의 값을 각각 제거하고 가속도합계변수를 새로 더하였다. 또한 센서데이터 에션 데이터 불균형을 해결하기 위해 각 자해환자의 자해시간을 기준으로 24시간 동안의 센서 데이터를 언더샘플링을 진행하였다. 또한 센서데이터의 표준화를 진행하여 데이터의

평균을 0으로 표준편차를 1로 만들어 데이터의 범위를 조절하였다[11].

$$Total\ Acceleration = \sqrt{X + Y^2 + Z^2}$$

(1)

[표 1] 정신병동 내의 인구학적정보(범주)

[Table 1] Demographic Information within the Psychiatric Ward (Category)

항목	구분	숫자
성별	여	61
	남	36
결혼여부	미혼	77
	기혼	15
	이혼	5
교육수준	초등학교 졸업	1
	중학교 졸업	14
	고등학교 졸업	62
	대학교 졸업 이상	20
종교	무교	48
	기독교	29
	불교	10
	천주교	9
	기타	1
직업	무직	37
	학생	20
	서비스/판매종사자	14
	사무직원	9
	가사	6
	단순노무 근로자	5
	군복무중	2
신체질환 유무	기타	4
	있음	63
	없음	34
정신질환	양극성 정동장애	18
	조현병	16
	중등도 우울에피소드	13
	기타	47

3. 연구 결과

3.1 CRF 모델

본 연구에서는 센서 데이터를 활용한 예측 모델 개발에 앞서, 조건부 랜덤 필드(CRF) 모델을 통해 기존의 여러 기계 학습 방법들의 성능을 평가하였다. 이러한 평가는 랜덤 포레스트, 로지스틱 회귀, XGBoost 등 다양한 알고리즘을 사용하여 수행되었다. [표 2]에서 제시된 바와 같이, 각 모델은 정밀도(Precision), 민감도(Sensitivity), F1 점수, ROC-AUC 값 등 여러 지표를 통해 성능이 평가되었다.

3.2 SHAP Value


데이터의 차원성과 모델의 복잡성은 임상 모니터링 시스템에서 매우 중요한 고려사항이다. 임상 환경에서 사용되는 모델은 높은 예측 정확도를 유지하면서도 계산 효율성과 사용의 용이성을 동시에 충족시켜야 한다.

[표 2] CRF 모델 성능 평가

[Table 2] CRF Model Performance

	Random Forest	Logistic Regression	XGBoost
Precision	0.7778	0.4000	0.7273
Sensitivity	0.5385	0.3077	0.6154
F1 Score	0.6364	0.3478	0.6667
ROC-AUC	0.7646	0.6424	0.8020

이를 위해 모델의 입력 차원을 줄이는 차원 축소는 필수적인 전처리 단계가 될 수 있다. 본 연구에서는 46개의 정신 척도 문항을 포함한 CRF 데이터셋에 대하여, SHAP(Shapley Additive exPlanations)값을 활용하여 변수의 중요도를 평가하였다. SHAP 값은 게임 이론의 샤플리 값에 기반을 두고 있으며, 각 변수가 모델의 예측에 기여하는 정도를 정량화하는 강력한 방법론이다[12]. 본 연구에서 SHAP 값을 분석한 결과, [그림 5]와 같이 변수 중요도에 따라 CRF xgboost 기계학습 모델을 기반으로 상위 10개의 변수를 추려내었다. 추려진 변수들은 아래 그림에서 확인 할 수 있다.

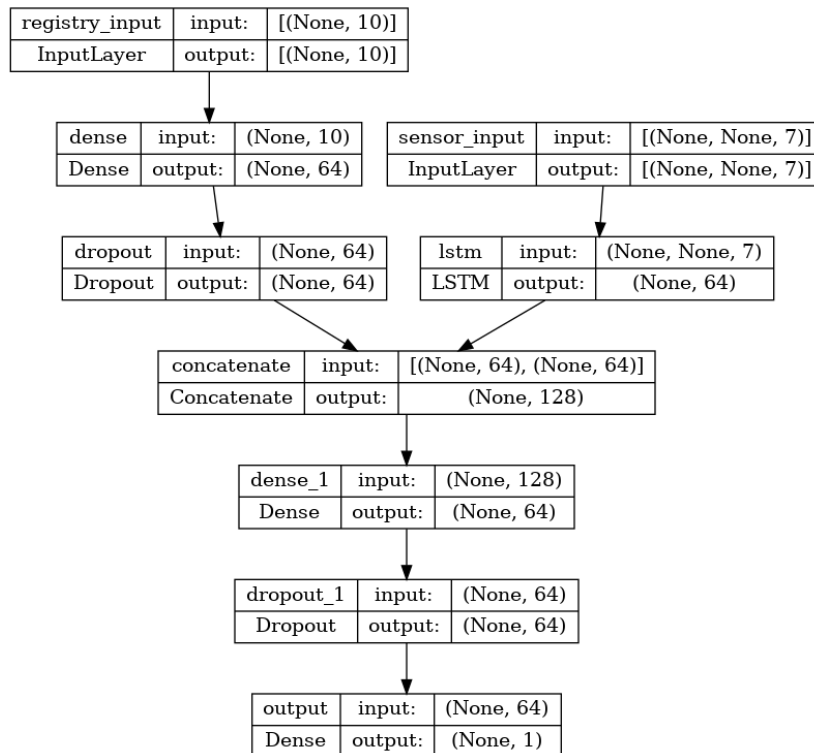


[그림 5] SHAP 값

[Fig. 5] SHAP Value

3.3 모델 구축

이 연구에서 제안하는 모델은 다중 입력 신경망으로, CRF 데이터와 센서 데이터를 동시에 처리하여 해당 시간에 환자들이 자살을 시도할지 예측하는 이진 분류 작업을 진행한다. 모델의 구조는 크게 두 개의 병렬 구조로 구성되며, 이는 각각 CRF 데이터와 센서 데이터를 처리한다. 모델의 구성 요소는 [그림 6]과 같다. CRF데이터의 레이어층은 다음과 같이 구성된다. SHAP Value를 통한 변수 중요도에 따라 Input Layer를 CRF 모델에서의 SHAP Value값을 이용하여 10개의 특성을 처리하도록하였다. Dense Layer는 64개의 뉴런을 가진 밀집층으로, 활성화 함수 ReLU를 사용하였다[13]. 이 레이어는 입력 데이터의 비선형 표현을 학습한다. Dropout Layer는 과적합 방지를 위하여 특정 비율의 뉴런을 임의로 비활성화 하였다. 센서데이터는 Input Layer는 가변 길이의 시계열 센서 데이터를 입력으로 받는다. 입력 데이터는 총 7개의 특성을 가진다. LSTM Layer는 시계열 데이터의 시간적 패턴을 학습하기 위해 사용되는 LSTM 레이어이다. 이 레이어는 64개의 뉴런을 가지며, 시퀀스 데이터에서 장기 의존성을 모델링 할 수 있다. Concatenate Layer는 CRF 데이터 경로와 데이터 경로에서 나온 결과를 결합한다. Dense Layer는 결합된 데이터를 처리하기 위한 추가 밀집층이다. 64개의 뉴런을 사용하여 , ReLU 활성화 함수를 적용하였다. Dropout Layer는 CRF데이터의 Dropout Layer 와 같이 과적합을 방지하기 위한 또 다른 드롭아웃 층이다. 마지막 Output Layer는 최종 출력층으로, 하나의 뉴런을 가지며 시그모이드 활성화 함수를 사용한다[14]. 이 레이어는 이진 분류 작업의 결과를 예측한다.복잡한 데이터 구조를 효과적으로 처리하고, 정적 특성을 가진 CRF 데이터와 동적 특성을 가진 시계열 센서 데이터를 모두 고려한 예측을 수행할 수 있다.



[그림 6] 모델 레이어 시각화

[Fig. 6] Model Layer

3.4 평가 지표

모델의 성능을 평가하기 위해 다양한 성능평가가 진행되었다. Sensitivity는 실제 양성 케이스를 모델이 양성으로 정확히 예측한 비율을 나타내며, 특히 1을 예측하는 능력을 평가하는데 중요하다. F1-Score는 정밀도와 민감도의 조화 평균으로, 두 지표를 동시에 고려할 때 유용하다. Precision은 모델이 양성으로 예측한 결과들 중 실제로 양성인 경우의 비율을 말한다. Roc-auc는 모델이 양성 클래스를 얼마나 잘 구분하는지를 나타내는 지표로, AUC 값이 1에 가까울수록 모델의 성능이 우수함을 의미한다. 이와 같은 평가지표로 모델의 성능을 평가하였다. 이러한 평가 지표들을 통해 모델의 성능을 평가하였다[15].

3.5 모델 검증

본 연구에서는 개발된 예측 모델의 성능을 검증하기 위해 별도의 검증 데이터 셋을 사용하였다. 모델의 일반화 능력을 평가하기 위해, 전체 데이터셋을 훈련 데이터(60%), 검증 데이터(20%), 테스트 데이터(20%)로 분할하여 진행하였다. 이러한 분할은 데이터의 다양성을 보장하고, 모델의 성능이 특정 데이터셋에 과적합되지 않도록 하기 함이다.

[표 3] 모델 성능 평가

[Table 3] Model Evaluation

성능지표	validation	test
Precision	0.2770	0.2660
Sensitivity	0.7845	0.8049
F1-Score	0.4095	0.3998
ROC-AUC	0.9532	0.9861

사용된 분류 모델은 검증 데이터셋에 대해 [표 3]과 같이 27.70%의 정밀도와 78.45%의 재현율을 달성하였으며, F1점수는 40.95%로 측정되었다. 테스트 데이터셋에 대해서는 정밀도가 약간 낮은 26.60%였고, 재현율은 80.49%였다. F1 점수는 39.98%였다. CRF 모델들의 정밀도(Precision)가 높았지만, 생체 신호 데이터를 추가한 모델은 훨씬 더 높은 민감도를 달성하였다. 이는 모델이 실제 양성 케이스를 놓치지않고 잘 잡아내고 있음을 의미한다. 높은 민감도는 질병 진단에 있어서 중요한 평가 지표이다. 센서 데이터의 증례지 데이터를 통합하여 구축한 모델이 기존 모델보다 높은 민감도를 달성함으로써, 특히 충동적 자살 감지와 같은 중요한 의료 분야에서 가치를 입증할 수 있다.

4. 결론

본 연구는 정신병동에 입원한 환자들을 대상으로 한 증례지 데이터(CRF)와 센서 데이터를 종합하여, 충동적 자살 행위를 예측하는 LSTM(Long-Short-Term Memory) 기반의 딥러닝 모델을 개발하고 적용하였다. 이 모델은 다차원 데이터를 통합하는 방식으로 설계되었으며, 그 결과 민감도를 향상시킬 수 있었다. 높은 민감도는 실제 자타해 행동을 선별하는데 필요하여, 이는 임상현장에서 본 모델을 적용할 때 장점으로 작용할 것이며,

특히 충동적 자타해와 같이 즉각적인 개입이 필수적인 상황에서는 유용하다. 이러한 접근방식은 위기 상황을 신속하고 효과적으로 개입할 수 있게 하여 병동 안전을 개선하고 병동 종사자들의 노동 강도를 경감하는데 도움을 주는 기술적 기반으로 마련할 것으로 기대된다. 첫째, 정신병동 내 충동적 자살 행위는 환자 안전과 직접적으로 연관된 중요한 문제로, 본 연구는 실시간으로 변화하는 생체 신호 데이터를 통합함으로써 보다 정확한 예측을 가능하게 한다. 둘째, CRF 데이터와 센서 데이터를 동시에 처리하는 다중 입력 신경망 모델을 제안하여, 기존의 단일 데이터 소스 기반 모델보다 높은 예측성능을 달성하였다. 셋째, 높은 민감도를 통해 실제 자타해 행동을 정확히 예측할 수 있는 본 모델은 임상현장에서 실질적으로 활용될 수 있어 환자 안전을 강화하고 의료진의 부담을 경감하는데 기여할 수 있다. 마지막으로 정적특성(CRF 데이터)과 동적 특성(센서 데이터)을 통합함으로써 더 포괄적인 분석이 가능해졌고, 예측의 정확도를 높였다. 향후 연구 방향으로는, 추가적인 환자 데이터를 수집하여 모델의 예측 능력을 더욱 일반화하고, 정신병동 내에서 환자의 위치 정보를 모델에 적용함으로써 충동적 자타해 행위 예측의 정확성을 높이는 것을 목표로 한다.

5. 감사의 글

본연구는 보건복지부의 재원으로 한국보건산업진흥원의 보건의료기술연구개발사업(과제 : HI22C1569)과 한국연구재단의 기초연구사업(grant number: NRF-2022R1F1A1069069) 지원에 의하여 이루어진 것임.

References

- [1] <https://www.who.int/publications/i/item/9789240026643>, June 16 (2021)
- [2] https://www.mohw.go.kr/board.es?mid=a10411010100&bid=0019&tag=&act=view&list_no=369858, Jan 20 (2022)
- [3] <https://seoulmentalhealth.kr/indicators/dashboard>, Apr 03 (2024)
- [4] Tianze Sun, Xiwang He, and Zhonghai Li, Digital twin in healthcare: Recent updates and challenges, Digital Health, Sage Publications, (2023)
DOI: 10.1177/20552076221149651
- [5] Seung-Ju Lee, Hyun-Ji Moon, Da-jung Kim, and Yourim Yoon, Genetic algorithm-based feature selection for depression scale prediction, Proceedings of the 2019 International Conference on Machine Learning and Computing, ACM, (2019)
DOI: 10.1145/3319619.3326779
- [6] Min Kang, Seokhwan Kang, and Yongho Lee, Prediction of Beck Depression Inventory Score in EEG: Application of Deep-Asymmetry Method, Applied Sciences, (2020), Vol.11, No.19, pp.9218.
DOI: 10.3390/app11199218
- [7] Michael D. Anestis, Kelly A. Soberay, Peter M. Gutierrez, Theresa D. Hernández, and Thomas E. Joiner, Reconsidering the Link Between Impulsivity and Suicidal Behavior, Personality and Social Psychology Review, (2014), Vol.18, No.4, pp.366-452.
DOI: 10.1177/108886831453598
- [8] Andrew T. Gloster, Andrea H. Meyer, Jens Klotsche, Jeanette Villanueva, Victoria J. Block, Charles Benoy, Marcia T. B. Rinner, Marc Walter, Undine E. Lang, and Maria Karekla, The spatiotemporal movement of patients in and out of a psychiatric hospital: an observational GPS study, BMC Psychiatry, (2021), Vol.21, 165.

DOI: 10.1186/s12888-021-03147-9

- [9] Edwin D. Boudreaux, Elke Rundensteiner, Feifan Liu, Bo Wang, Celine Larkin, Emmanuel Agu, Samiran Ghosh, Joshua Semeter, Gregory Simon, and Rachel E. Davis-Martin, Applying Machine Learning Approaches to Suicide Prediction Using Healthcare Data: Overview and Future Directions, *Frontiers in Psychiatry*, (2021), Vol.12.
DOI: 10.3389/fpsyt.2021.707916
- [10] Dror Ben-Zeev, Emily A. Scherer, Rachel M. Brian, Lisa A. Mistler, Andrew T. Campbell, and Rui Wang, Use of Multimodal Technology to Identify Digital Correlates of Violence Among Inpatients With Serious Mental Illness: A Pilot Study, *Psychiatric Services*, (2017), Vol.68, No.10.
DOI: 10.1176/appi.ps.201700077
- [11] Arlind Kadra, Marius Lindauer, Frank Hutter, and Josif Grabocka, Regularization is all you Need: Simple Neural Nets can Excel on Tabular Data, *arXiv*, (2021)
DOI: 10.48550/arXiv.2106.11189
- [12] S. M. Lundberg, and S. I. Lee, A unified approach to interpreting model predictions, *Proceedings of the Advances in Neural Information Processing Systems*, (2017), pp.4765-4774.
Available from: <https://proceedings.neurips.cc/paper/2017/hash/8a20a8621978632d76c43dfd28b67767-Abstract.html>
- [13] Abien Fred Agarap, Deep Learning using Rectified Linear Units (ReLU), *arXiv*, (2018)
DOI: 10.48550/arXiv.1803.08375
- [14] Matías Roodschild, Jorge Gotay Sardiñas, and Adrián Will, A new approach for the vanishing gradient problem on sigmoid activation, *Progress in Artificial Intelligence*, (2020), Vol.9, pp.351-360.
DOI: 10.1007/s13748-020-00218-y
- [15] Stephen V. Stehman, Selecting and interpreting measures of thematic classification accuracy, *Remote Sensing of Environment*, (1997), Vol.62, No.1, pp.77-89.
DOI: 10.1016/S0034-4257(97)00083-7